

音视频评测报告-PALM

摘要

本报告对国内主流四款音视频一体化生成模型——即梦（Seedance 2.0）、可灵（Kling 3.0）、快乐马（HappyHorse 1.0）、Vidu Q3——进行了一次系统化横向评测。基于 168 条标准化测试样本（4 模型 × 7 场景 × 3 方向 × 2 难度），由 5 名标注员按 10 个维度（5 个画面维度 + 4 个音频维度 + 1 个音画同步维度）进行 1-5 分打分，并经 2 名质检员二次审核，最终得出可追溯到每条原始评分的量化结论。

核心结论

- 综合排名：即梦 4.71 > 可灵 4.47 > 快乐马 4.31 > Vidu Q3 4.22。

一、背景与目标

1.1 项目背景

2024 年 OpenAI 发布 Sora 之后，音视频一体化生成正式成为 AI 视频赛道的里程碑能力——视频不再是「哑巴默片」，而是可以同时输出带原生音轨的画面、人物开口说话、口型同步、环境音效。国内外头部模型迅速跟进，但能力差距巨大：有的模型画面强但音频「贴脸糊」，有的音画对齐但情绪寡淡；具体差距在哪个维度，没有一份系统化的横向评测能给出答案。

我们需要对当前主流竞品进行一次系统化评测，输出一份可量化、可追溯、可用于商务接入和算法迭代决策的选型与归因报告，全面了解市场格局、识别产品的优势与短板，从而帮助公司制定更加精准的产品策略和差异化定位。

1.2 评测目标

本次评测希望系统性回答以下三个核心问题：

- 综合能力对比：**通过多维度量化打分，得出四款模型在标准化评测体系下的综合能力排名，明确各模型整体实力梯队。
- 场景适配性分析：**识别每款模型在 7 大业务场景下的优势区与短板区，为不同业务方向提供「场景—模型」匹配建议。
- 业务落地参考：**基于评测结论输出可执行的选型建议，帮助业务方在直播带货、内容创作、广告制作、游戏宣发等具体场景下选择最优模型，降低试错成本。

二、竞品选择依据

2.1权威排行榜参考

我们主要参考了两个第三方独立排行榜的「Text-to-Video Leaderboard（含音频）」赛道：

- **Artificial Analysis**：独立第三方 AI 评测公司，不归属任何大厂；其 Elo 评分被 Kling、Google、Runway 等厂商本身用作对标镜，也被 VentureBeat、The Verge、Ars Technica、DataCamp 等技术媒体作为横评的直接引用数据源。
- **JAI Portal**：面向内容创作者和中小型创意机构的工具横评平台，TikTok / Instagram / YouTube Shorts 类创作者活跃度高。

2.2自媒体测评参考

我们覆盖了 B 站、抖音、YouTube 等平台近两个月所有热门 AI 视频测评内容，并精选无广冷门视频，扒取评论区真实用户体验，参考其产品选择、测试维度以及最终效果评价，作为排行榜数据的补充。

2.3最终选定的 4 款模型

竞品	版本	厂商	发布时间	核心架构	关键特点 / 入选理由
即梦	Seedance 2.0	字节跳动	2026.02	多流 DiT 架构	在 Artificial Analysis 与 JAI Portal 中表现优异；全球暂停但国内可用；音视频生成能力均衡。
可灵	视频3.0	快手	2026.05.11	All-in-One 多模态统一架构	原生 4K 输出、15秒智能分镜、特定场景生成能力强；当前最佳「能用性」模型。
快乐马	HappyHorse 1.0	阿里巴巴	2026.04.27	40层单流 Transformer 统一架构	业界首创原生音视频同生成、7种推理模式；单张 H100 5 秒 1080P 视频生成。
Vidu	Vidu Q3	生数科技 × 清华大学 AI 研究院	2026.02.25	原创 U-ViT 融合架构（Diffusion + Transformer）	在自媒体短视频领域被频繁提及，生成效果优秀（漫剧 1080P/15 秒成本品）。

三、评测方案

3.1 数据集构建

- 数据来源：采用文生视频方式构建，统一控制输入条件，保证 4 个模型在公平、可复现的条件下进行横向对比。
- 规模：7 大场景 × 3 个方向 × 2 条数据（简化版 prompt + 复杂版 prompt）× 4 个模型 = 168 条数据。

- 统一规格：画幅 16:9，分辨率 1080P，时长 5 秒。

七大场景与分支

场景	具体分支	评测重点
宠物	动物间交互 / 宠物吃播 / 与人交互	画面美感、音效同步、主体稳定、
音乐	吉他独奏 / 音乐 MV / 音乐节现场	音频呈现力、节奏感、情绪匹配
数字人	直播带货 / 虚拟偶像 VTuber / 新闻播报	口型同步、人声清晰、台词遵循
食品餐饮	烹饪 / 食品广告 / 吃播	画面美感、氛围感、声音质感
游戏	NPC 交互 / 使用道具 / 宣传 CG	动作质量、音效同步、画面稳定
体育竞技	田径 / 游泳 / 篮球	运动质量、音效同步、物理合理性
多人交互	情绪交互 / 冲突场景 / 教学问答	多人画面合理性、声音数量响应、口型对应

3.2 评分体系

每个生成视频由评测员从 10 个独立维度进行 1-5 分打分，10 个维度分为三组：5 个画面维度、4 个音频维度、1 个音画同步维度。简化版与复杂版 prompt 两组得分按总分相加，得出最终模型在该场景下的综合表现。所有评分通过 Excel 公式自动计算，任何最终得分都可以追溯到具体维度的原始评分。

1-5 分锚点定义

分值	等级	规则解释
5	优秀	内容整体稳定自然，几乎无可感知缺陷，不影响观看、理解与沉浸体验。
4	良好	存在少量轻微缺陷，偶尔能够察觉，但不影响主要内容表达与正常观看体验。
3	合格	存在多处明显缺陷，用户能够注意到违和感，但仍可理解主要内容。
2	较差	缺陷频繁出现或存在较严重错误，已经明显干扰观看体验、内容理解或真实感。
1	崩坏	内容存在持续性严重异常或核心功能失效，用户无法正常理解或观看。

10 维度评判角度

维度	评判角度
画面质量	清晰度 / 压缩痕迹 / 卡顿跳帧 / 过曝过暗 / 是否影响观看
画面遵循	主体动作响应 / 辅助主体响应 / 风格响应 / 镜头响应 / 环境响应
主体一致性	形象改变（侧脸正脸是否同人） / 五官稳定 / 服装发型颜色一致 / 主体数量一致 / 主体消失、替换、
运动质量	运动连续性 / 运动合理性 / 运动稳定性 / 运动生动性
现实合理性	空间关系 / 重力错误 / 物理结构 / 材质真实度 / 光影逻辑
画面表现力	光影色彩氛围 / 构图 / 情绪感故事感 / 运镜美感 / 视觉感染力
音画同步	多、少口型 / 错口型 / 角色发声对应 / 画外音旁白成口型 / 多/少音效
音频质量	清晰度/连续性/卡顿/纯净度/音量异常
音频遵循	台词内容 / 主体人物遵循 / 声音数量响应 / 方言语种口音响应 / 音效缺失
音频呈现力	说话机械感重 / 歌唱表现差 / 情绪表现不足 / 音效节奏不自然 / 整体氛围感不足

四、评测结果

4.1 综合能力排名

对所有 168 条评分取平均，四款模型的综合得分排名如下：




图1：四款模型综合能力排名

排名	模型	单条均分(/50)	维度均分(/5)	累计总分	标准差	评价

No.1	即梦	47.12	4.71	1979	2.91	梯队领先
No.2	可灵	44.69	4.47	1877	3.23	稳定第二
No.3	Happy Horse	43.12	4.31	1811	4.64	上限高、波动大
No.4	Vidu	42.17	4.22	1771	4.20	均衡偏弱


横向对比要点

即梦与可灵之间相差 2.43 分，可灵与第二梯队（Happy Horse、Vidu）之间相差约 1.5–2.5 分，呈现“一超一强两追赶”格局；

Happy Horse 标准差最高（4.64），表明其表现极不稳定——存在满分案例的同时也有大量低分案例，上限高但下限低；

即梦标准差最低（2.91），说明它不仅强，而且稳，在各类数据上表现一致性最好。

4.2 十维度能力对比



纵向对比要点

从雷达图可以看到四个明显的事实：


- 即梦“无短板”：10 个维度全部第一，其中音画同步（4.90）、运动质量（4.83）、主体一致性（4.81）为其最强项；
- 全模型共性短板集中在「画面遵循」「现实合理性」「画面表现力」「音频呈现力」——即指令理解与美学/情绪表达，是当前一体化生成的技术难点；
- Vidu 在 8 个维度垫底，画面表现力（3.62）、音频呈现力（3.86）尤为薄弱，反映其在审美加工与情绪渲染上的代际差距；
- Happy Horse 唯一垫底维度是「画面遵循」（3.67），是其与第一梯队拉开差距的关键短板。

精确数值表

维度	Happy Horse	即梦	可灵	Vidu	最强	最弱
----	-------------	----	----	------	----	----

画面质量	4.55	4.74	4.38	4.26	即梦	Vidu
画面遵循	3.67	4.67	4.33	4.07	即梦	Happy Horse
主体一致性	4.62	4.81	4.69	4.55	即梦	Vidu
运动质量	4.55	4.83	4.71	4.40	即梦	Vidu
现实合理性	4.00	4.64	4.29	4.05	即梦	Happy Horse
画面表现力	4.07	4.48	4.19	3.62	即梦	Vidu
音画同步	4.83	4.90	4.83	4.71	即梦	Vidu
音频质量	4.64	4.86	4.62	4.52	即梦	Vidu
音频遵循	4.19	4.64	4.50	4.12	即梦	Vidu
音频呈现力	4.00	4.55	4.14	3.86	即梦	Vidu

4.3 七大场景能力对比



场景洞察


- 最强场景（数字人 4.43–4.95）：四模型在数字人场景普遍表现最佳，口型同步与人声清晰度成熟，最适合规模化商用；
- 最难场景（体育竞技 3.72–4.22）：篮球、田径等高速运动 + 复杂物理交互对所有模型都是挑战，Happy Horse、Vidu 在篮球分支低至 3.45；
- 即梦的最大优势区：食品餐饮（4.92）与数字人（4.95），相对其余三家拉开 0.5 分以上差距；
- 可灵的相对亮点：音乐场景 4.77 紧贴即梦，是其最具竞争力的场景；

- **Vidu 的普遍短板：**宠物场景仅 3.88（垫底），过饱和、清晰度不足、卡通化等画面问题在写实宠物场景尤为突出。

每个场景的最佳模型

场景	Happy Horse	即梦	可灵	Vidu	场景冠军
数字人	4.65	4.95	4.70	4.43	即梦
多人交互	4.70	4.88	4.73	4.40	即梦
音乐	4.57	4.82	4.77	4.53	即梦
宠物	4.27	4.65	4.32	3.88	即梦
食品餐饮	4.15	4.92	4.42	4.37	即梦
游戏	4.13	4.55	4.22	4.10	即梦
体育竞技	3.72	4.22	4.13	3.80	即梦

4.4 视觉能力 vs 音频能力分项对比



模型	视觉能力(6维)	音频能力(4维)	视-音差值	特征
即梦	4.69	4.74	-0.04	音视频均衡，双优
可灵	4.43	4.52	-0.09	音频略强，画面表现力待提升

Happy Horse	4.24	4.42	-0.18	音频明显强于画面，画面遵循拖累
Vidu	4.16	4.30	-0.14	双项偏弱，画面表现力为最大短板

4.5 指令稳定性：简化版 vs 复杂版 prompt

每个方向均设置简化版与复杂版两档 prompt，用以考察模型在指令复杂度上升时的稳定性。结果显示：随着指令变复杂（多段时序动作 + 多重音效要求），多数模型出现不同程度衰减，但幅度有限；其中可灵反而在复杂 prompt 上略有提升（+0.08），表现出最强的复杂指令解析能力。





图6：简化版与复杂版 Prompt 平均分对比

模型	简化版	复杂版	变化	解读
即梦	4.76	4.67	-0.09	高位稳定，复杂指令仍保持高水准
可灵	4.43	4.51	+0.08	唯一正向，复杂指令解析能力突出
Happy Horse	4.39	4.24	-0.15	复杂指令下遵循能力明显下滑
Vidu	4.30	4.13	-0.17	衰减最大，复杂时序处理偏弱

五、低分与崩坏案例分布

统计各模型出现 ≤ 2 分（较差/崩坏）的评分次数，可直观反映模型的“下限”与风险点。Happy Horse 共出现 15 次低分（最多），Vidu 11 次，而即梦仅 1 次、可灵 3 次——前两者“翻车”概率远高于第一梯队。从维度看，低分高度集中在「画面遵循」（全体 10 次），其次是「现实合理性」与「音频呈现力」（各 7 次）。



典型 Badcase 归因

Happy Horse：复杂动画指令“多处不遵循”，画面遵循曾出现 1 分；体育田径“不美观”、宠物“清晰度不够”；

Vidu：宠物场景“饱和度过高、部分过曝、过于卡通”；动物叫声不正确导致音频遵循 2 分；篮球“多人变形、模糊”；

可灵：偶发噪点；多人知识问答场景“黑板字看不清”，文字渲染是其细节短板；


即梦：几乎无崩坏，唯一可感知问题为多人知识问答“字看不清楚”，但整体仍达 5 分。

六、市场匹配分析

1.四模型市场定位总览

- 评测结论已明确能力梯队（即梦 > 可灵 > Happy Horse > Vidu）。
- 但“适合谁用”不只取决于能力，还取决于成本与厂商生态。把“综合能力”与“单条生成成本”两个维度叠加，四款模型呈现出清晰的差异化市场卡位。

价值—价格定位地图：能力 × 成本



模型	厂商	市场卡位	核心优势	目标市场
即梦	字节跳动	全能性价比之王	能力第一且单条成本最低，背靠抖音生态	追求稳定交付的全场景商用用户
可灵	快手	影视级精控	能力第二，单价偏高，有导演共创计划	重质感与复杂创作的专业团队
HappyHorse	阿里巴巴	音频社媒利器	音频强、极速推理，背靠阿里生态	音频优先、求快的社媒玩家
Vidu	生数科技 × 清华	低成本入门	价格极具竞争力，无限生成档	预算敏感的入门与轻度用户

2.分模型市场分析：分别适合谁用

01即梦（字节跳动）——全能性价比之王

综合 47.1/50 · 全场景第一 · 单条成本最低 0.1-0.19 元

适合谁用

- 中大型 MCN / 品牌内容团队：要求开箱即用、稳定可交付，即梦 10 维全第一、最稳（σ=2.9），且单条成本最低，规模化生产性价比无敌。

- **直播带货 / 数字人口播商家：**数字人 4.95 全场最高，口型与人声成熟，背靠抖音电商生态，转化链路天然打通。
- **广告 / 短剧创作者：**食品广告 4.92 领先，画面质感佳；与抖音的 AIGC 短剧招募计划提供流量与资金扶持。

市场判断与打法

即梦是“通杀型”选手——能力天花板 + 成本地板 + 流量生态三位一体，几乎适配所有 C 端创作者与 B 端商业客户。市场打法上，应主打“一个模型搞定全场景、且最便宜”，并借抖音生态做内容分发与商业闭环。唯一需补强的是面向极致预算敏感用户的轻量入口。

最佳客户画像

专业内容团队、电商商家、广告/短剧工作室——要稳、要交付、要规模化，且看重性价比的中高频商用用户。

02可灵（快手）——影视级精控

综合 44.7/50 · 复杂指令反升 · 单条 1.25-1.5 元，影视级路线

适合谁用

- **广告分镜师 / 进阶创作者：**写得出复杂分镜脚本，可灵是唯一复杂版 prompt 反而提升 (+0.08) 的模型，复杂指令解析能力最强。
- **影视 / 短片创作者：**快手联合知名导演的“导演共创计划”探索 AI 电影级短片，可灵的运动一致性 (4.71) 与主体一致性 (4.69) 适配叙事性内容。
- **音乐 MV 制作方：**音乐场景 4.77 紧贴即梦，是其最具竞争力的场景。

市场判断与打法

可灵单价偏高（约为即梦的 10 倍），注定它不打“性价比”牌，而应走“专业·精控·影视级”的高价值路线，吸引愿为复杂创作与质感付费的专业用户。市场打法上，应放大“复杂指令解析”这一差异化心智与导演共创的影视背书，主攻 B 端专业团队与高客单价创作者，而非价格敏感的大众市场。

最佳客户画像

广告公司、影视/短剧团队、专业创作者——写复杂脚本、追求质感与可控性、愿为专业能力付溢价的高价值用户。

03Happy Horse（阿里巴巴）——音频社媒利器

综合 43.1/50 · 音画同步 4.83 · 极速推理 · 但波动大 ($\sigma=4.6$)

适合谁用

音频优先的社媒达人：重对话与口型、做口播段子，Happy Horse 音画同步 4.83、音频质量 4.64 扎实，业界首创原生音视频生成。

多人互动 / 教学内容方：多人交互 4.70 亮眼，适合教学问答、情绪互动类内容。

追求出片速度的玩家：极速推理是其卖点，能接受手动挑片、重抽取最佳，追求爆款上限而非每条都稳。

市场判断与打法

Happy Horse 的短板很明确：画面遵循 3.67 全场最低、稳定性最差（低分多达 20 次），不适合无人工质检的批量产线。它更适合作为“音频强项 + 速度”的细分利器，服务能容忍波动、靠人工挑片的社媒创作者。市场打法上，应聚焦音频与多人对话的差异化场景，同时把“降低翻车率、补齐画面遵循”作为产品迭代的第一优先级，才能从社媒玩家走向更广用户。

最佳客户画像

个人/小团队社媒创作者、口播与多人对话内容方——重声音、求速度、能手动挑片，且对画面遵循容忍度较高的用户。

04Vidu（生数科技 × 清华）——低成本入门

综合 42.2/50 · 价格极具竞争力 · 基础 48 元/月无限生成

适合谁用

- **预算敏感的入门 / 轻度用户：**学生、个人玩家，做着玩、发社交平台，价格/免费额度是第一决策因素，Vidu 无限生成档极具吸引力。
- **简单场景试水用户：**音乐 4.53、数字人 4.43 等简单场景勉强可用，音画同步 4.71 尚可，适合低要求的轻度创作。

市场判断与打法

Vidu 8 个维度垫底、复杂 prompt 衰减最大，画面美学是最大瓶颈，难以承接专业商用。其核心竞争力是“低价 + 无限生成”，最适合作为入门级、低成本的试水通道，靠价格吸引增量用户与价格敏感人群。市场打法上，应以低门槛、免费/低价无限档快速获客、做大用户基数，同时把“重做画面美学与色彩管理”作为向上拓展用户层级的关键。

最佳客户画像

学生、个人轻度用户、价格敏感的尝鲜者——低要求、用简单 prompt、把价格放第一位的入门级用户。

3.综合匹配矩阵与选型指引

把“用户类型 / 业务需求”与“四款模型”交叉，得到一张直接可用的匹配指引表，标注首选与备选。

用户类型 / 业务需求	首选	备选	匹配依据
专业内容团队 / 规模化商用	即梦	可灵	能力+成本+生态三优，规模化首选
影视短剧 / 复杂分镜创作	可灵	即梦	复杂指令解析最强 + 导演共创背书
直播带货 / 数字人电商	即梦	Happy Horse	数字人 4.95 + 抖音电商闭环

音频口播 / 多人对话社媒	Happy Horse	即梦	音画同步强、出片快，需人工挑片
音乐 MV / 演出内容	即梦	可灵	音乐场景两者均强（4.82/4.77）
入门尝鲜 / 预算敏感	Vidu	即梦轻量档	低价无限生成，做大用户基数
体育 / 高速运动等高难场景	即梦	可灵	全行业最难，仅即梦勉强达标，需人工质检

4.总体市场结论

- **即梦**——覆盖面最广的“通杀型”模型，从专业团队到电商商家、从广告到音乐都适配，是大多数用户的安全选择。
- **可灵**——差异化走影视级精控高价值路线，目标是愿为复杂创作与质感付溢价的专业团队，而非大众市场。
- **Happy Horse**——音频与多人对话的细分利器，服务能容忍波动、靠人工挑片的社媒创作者，需补齐稳定性。
- **Vidu**——低成本入门通道，靠价格做大用户基数，适合预算敏感的轻度尝鲜者，向上拓展需补画面美学。

七、结论与展望

7.1 核心结论回顾

本次基于 168 条标准化数据、10 个维度、7 大场景的横向评测得出明确结论：四款音视频一体化生成模型呈现“一超一强两追赶”的清晰梯队格局。

1. **即梦（综合第一）** ——单条均分 47.12，10 维全胜、7 场景全冠军且最稳定，是当前综合实力最强、最适合规模化商用的模型；
2. **可灵（综合第二）** ——单条均分 44.69，稳居第二梯队首位，复杂指令解析能力突出，是即梦之外最可靠的备选；
3. **Happy Horse（第二梯队）** ——单条均分 43.12，音频功底扎实、上限高，但受画面遵循短板与稳定性拖累；
4. **Vidu（第二梯队）** ——单条均分 42.17，各项均衡偏弱，画面美学表现力是最大瓶颈。

此外，评测还揭示两条行业级规律：其一，四款模型音频能力普遍略强于视觉能力，画面（尤其表现力与遵循）反而是当前一体化生成的瓶颈；其二，全行业共性短板集中在「画面遵循、现实合理性、画面表现力、音频呈现力」，即指令理解与美学情绪表达，是下一阶段技术攻坚的核心方向。

7.2 评测方法论的可信度

本次评测的方法论在以下三个层面具备严谨性：

- 样本控制：168 条样本统一画幅、分辨率、时长；每场景固定 3 个方向 × 2 难度，覆盖均衡。
- 评分可追溯：10 维度 × 1-5 分锚点定义清晰；所有汇总评分均可追溯到具体单条样本的原始评分。
- 双重审核：5 标注员 + 2 质检员，标注员之间打分一致性高（同条目跨人复评偏差 ≤ 1 分占比 $>95\%$ ）。

7.3 局限性与下一步

- 样本量局限：每个「场景 × 方向 × 难度」组合只有 1 条样本，单点偏差难以完全排除；后续可扩充至 3 条以上做方差分析。
- 场景覆盖：多人交互这类「全员失败」的场景，未来可拆分细化（情绪交互 vs 冲突 vs 教学）以判断到底是哪一类拖累了得分。
- 评分主观性：「画面表现力」「音频呈现力」类美学维度受标注员主观影响较大；下一版可引入「双盲打分 + 异议复议」机制。
- 成本/速度未纳入主排名：本评测仅以「质量」打分，Vidu Q3 的成本数量级优势未在主总分体现；后续可建立「质量/成本」综合指标。

7.4 给厂商的优化建议

对于希望提升模型表现的厂商，结合本评测的归因分析，优化优先级建议如下：

1. 第一优先级 — 画面表现力 + 音频呈现力（美学加工）：增加高美学训练样本，引入构图、色彩、运镜风格 token；音频侧引入情绪标注与节奏感监督。
2. 第二优先级 — 多人交互（全行业空白）：构建多人对话、冲突戏、教学场景的针对性数据集，攻克「多人物画面合理性 + 声音数量响应 + 多角色口型对应」联合建模。
3. 第三优先级 — 复杂 prompt 鲁棒性：针对长 prompt 分镜控制，增加「指令拆解 → 时序对齐」环节的训练；可灵的方法论值得参考。
4. 第四优先级 — 物理常识：现实合理性反映出物理穿模、光影逻辑等问题，可引入物理引擎仿真数据辅助训练。