

音视频评测规则文档

一、背景与目标

1.项目背景

- 2024 年 Sora发布后,音视频一体化生成成为 AI 视频赛道的里程碑能力——视频不再是“哑巴默片”,而是带有原生音轨、人物可开口说话、口型同步、环境音效一体化输出。国内外头部模型迅速跟进,但能力差距巨大:有的模型画面强但音频“贴脸糊”,有的音画对齐但情绪寡淡。
- 我们需要对当前主流竞品进行一次系统化评测,输出一份可量化的选型与归因报告,辅助商务接入与算法迭代决策,全面了解市场格局、识别产品的优势与短板,从而制定更加精准的产品策略和差异化定位。

2.评测目标

本次评测希望系统性回答以下三个核心问题:

- 综合能力对比** 通过多维度量化打分,得出四款模型在标准化评测体系下的综合能力排名,明确各模型的整体实力梯队。
- 场景适配性分析** 识别每款模型在7大业务场景(宠物、数字人、食品餐饮、游戏、体育竞技、音乐、多人互动)下的优势区与短板区,为不同业务方向提供"场景-模型"匹配建议。
- 业务落地参考** 基于评测结论输出可执行的选型建议,帮助业务方在直播带货、内容创作、广告制作、游戏宣发等具体场景下选择最优模型,降低试错成本。

二、评测概要

本次评测主要面向**音视频一体化生成模型**,评估不同模型在生成视频时,是否既能生成高质量画面,又能生成高质量的声音,并做到音画同步。

1.评测重点

模型能不能同时做好画面、声音、音画同步和场景适配。

具体场景:

- 数字人场景**重点看口型同步、人声清晰、台词遵循;
- 游戏/体育场景**重点看动作质量、音效同步、画面稳定;
- 食品/宠物场景**重点看画面美感、氛围感、主体稳定;
- 多人互动场景**重点看多人画面合理性、声音数量响应和口型对应。

最终目标是选出不同业务场景下最适合的模型，并找出各模型的主要短板。

2.评测对象说明


01.竞品选择

竞品名称	官方全称	开发公司	最新版本	发布时间	参数规模	核心架构	关键技术特点
可灵	可灵 AI 视频模型	快手	视频3.0	2026.05.11	未公开	All-in-One 多模态统一架构	原生 4K 输出、特征步、15 秒智能分镜、绑定（主体 + 音色双
即梦	即梦 AI 视频生成模型	字节跳动	Seedance 2.0	2026.02	未公开	多流 DiT 架构	四模态混合输入、原同步、角色一致性保Seedream 5.0 Lite生打通
快乐马	HappyHorse（快乐小马）	阿里巴巴	1.0	2026.04.27	150 亿参数	40 层单流 Transformer 统一架构	业界首创原生音视频成、7 种语言精准唇步极速推理、单张卡5 秒 1080P 仅需 38
维度	Vidu（维度）AI 视频生成大模型	北京生数科技有限公司 联合清华大学	Q3	2026.02.25	未公开	原创 U-ViT 融合架构（Diffusion + Transformer）	最长 16 秒声画同出级特效（粒子 / 流体等）、5 大类音效生结构控制技术、多剪辑与运镜调度

02.我们为什么要选择这4个竞品？

- 本次选取可灵、即梦、快乐马、维度等 4 个模型作为评测对象，主要基于其市场代表性、技术差异性和应用覆盖度。
- 这些产品覆盖了国内主流音视频生成厂商，在长视频生成、音画同步、角色一致性、物理动态等关键能力上各有特点，能够较全面地反映当前国内 AI 音视频生成产品的能力水平。
- 通过对这些模型进行横向评测，可以获得具有代表性和参考价值的竞品分析结论。

3.评测场景



4.数据来源

本次评测采用文生视频的方式构建数据集，统一控制输入条件，从而保证 4 个模型在公平、可复现的条件下进行横向对比。

5.数据集规模

- 我们现在有四个竞品模型，构建了7个场景，每个场景3个方向，每个方向2条数据，总体的数据规模是168条数据。
- 具体场景的每个方向从简化版prompt和复杂版prompt两个难度，来评测ai的音视频生成情况。
- 每个视频统一画幅16：9，分辨率1080p，时长5s。

6.音视频数据集

[📺 音视频数据集](#)

7.数据集字段说明

字段名	含义
场景	评测视频场景方向
分支	具体场景分支
prompt	文本
竞品1（happy horse）	竞品1生成的音视频数据
竞品2（即梦）	竞品2生成的音视频数据
竞品3（可灵）	竞品3生成的音视频数据
竞品1（vidu）	竞品4生成的音视频数据
维度	具体评判的规则维度
评分	1-5分
备注	评分原因
总分	评分合计

三、评测方案

1.人员配置

角色	人数	主要职责
标注员	6人	数据评分
质检员	2人	审核数据评分是否合理

2.项目周期

项目周期：2天
工作天数：2天
每日工作时效：8小时

3.人效测算

角色	人数	每人每小时	每人每天	团队每天
标注员	5人	5条/小时	40条/天	200条/天
质检员	2人	11条/小时	88条/天	176条/天

4.评测步骤

标注员评测步骤：

步骤	内容
第一步	规则文档培训，熟悉评测规则
第二步	查看数据
第三步	根据规则维度进行打分
第四步	备注打分原因

质检员质检步骤：

判断每条数据的分值及原因是否正确合理。

5.评测办法

评分法（对数据进行打分）

通过预设的评分标准和维度，对模型生成的回答进行打分，量化评价模型的表现。

为每个维度制定清晰、可操作的评分规则。		
分值	规则	规则解释
5	非常满意	答案正确且满足通用规则，音视频质量完美，内容优质，内容可直接在实际场景中使用。
4	满意	答案正确，视频or音频上不够完美，有些瑕疵，但也可以在实际场景中使用。
3	部分满意	不影响整体观看和理解，内容有部分错误（不超过50%）
2	微弱价值	内容大量问题（大于50%），影响观看和理解，内容要使用需经过人工大量修改。
1	无价值	内容毫无价值，完全不可用，答非所问等。

对每个竞品的最终得分进行排名，判断模型优劣。

四、评测规则

1.评分体系总体架构

每个生成视频由评测员从七个独立维度进行1-5分打分，将极简与复杂提示词两组得分按总分相加得出最终模型在该场景下的综合表现。所有评分通过Excel公式自动计算,任何最终得分都可以追溯到具体维度的原始评分。

2.规则维度评分详解

每个维度采用1-5分制,锚点描述如下:

维度	5分(优秀)	4分(良好)	3分(合格)	2分(较差)	1分(崩坏)
画面质量	画面清晰稳定，几乎没有可见的模糊、噪点、压缩痕迹、曝光异常或边缘破损，整体成像干净。	存在轻微成像瑕疵，例如局部轻微模糊、少量噪点或轻微压缩感，但不影响正常观看。	存在较明显的成像问题，例如画面整体偏糊、细节损失、噪点较多或曝光不稳定，但仍能看清主要内容。	成像问题频繁且明显，例如大面积糊化、严重噪点、明显压缩块、过曝/欠曝影响画面辨认。	画面严重失真、破碎、模糊或曝光异常，已经难以正常观看。
画面遵循	核心要求全部正确呈现，且没有明显跑题，完全遵循提示词	大部分核心要求正确，只有一两个次要细节缺失或轻微偏差。	主要主题还在，但多个细节缺失，或动作、场景、风格中有一项明显不准。	只保留了少量关键词，主体、场景或动作中至少一项严重偏离。	基本不符合prompt，生成内容与要求几乎无关。
主体一致性	主体全程稳定，没有可见变脸、变形、换装、消失或数量变化。	有轻微外观波动，但身份和主体结构始终可识别。	出现 1-2 次明显变化，例如脸部短暂变形、服装颜色漂移、物体形态变化，但不影响整体理解。	主体多次明显变化，身份、数量或结构稳定性较差。	主体严重崩坏、变脸、消失、数量变化，已无法判断是否为同一对象。
运动质量	动作连续自然，肢体、物体接触和运动方向均合理。	有轻微卡顿或小幅不自然，但不影响动作理解。	动作大体可识别，但存在明显卡顿、关节异常、接触不准或局部穿模。	动作经常不连贯，存在多处肢体扭曲、穿模或运动跳变。	动作基本崩坏，无法判断角色或物体在做什么。
现实合理性	整体符合现实规律与人类常识；无明显违和。无物理性穿模或浮空	存在轻微不合理现象；但整体真实感较强。	存在明显现实错误；用户能够察觉违和。	现实错误频繁；严重影响观看体验。	大量物理、空间或逻辑错误；整体缺乏可信度。
画面表现力	构图成熟，主体突出；光影、色彩、氛围高度统一；画面有情绪、有故事感；	主体清晰，构图较好；色彩和光影有设计感；氛围明确；画面有一定情绪表达或	能看清主体和内容；构图、色彩、光影基本合理；画面信息表达清楚，但缺少	主体不够突出；构图普通或略显混乱；色彩、光影缺乏层次；画面情绪弱，故事感不足；整体像	主体混乱或不明确；构图失衡；色彩脏乱或过于平；光影不合理；画面没有氛围和

	细节丰富但不杂乱	视觉张力；整体观感舒服。	强烈氛围、情绪或设计感。	“生成出来了”，但缺少审美加工	情绪；细节粗糙，甚至影响用户理解内容
音画同步	关键声音与画面事件高度同步，例如口型、脚步、碰撞、开门、转场等时间点基本一致。	整体同步，个别声音有轻微提前或滞后，但不影响观看。	大体能对应画面，但多个关键声音存在可感知延迟、提前或节奏不稳。	声音和画面经常错位，关键事件的声音明显不在对应时间点。	音频与画面时序基本无关，像是随机配上的声音。
音频质量	声音清晰稳定，层次自然，无明显噪声、爆音或失真。	有轻微噪声或局部不稳定，但整体听感正常。	存在可感知杂音、混浊、音量不稳或层次单一，但仍能听清主要声音。	音频质量较差，噪声、失真、断裂或混乱明显影响理解。	严重失真、爆音、断裂或无法听清
音频遵循	声音类型与画面事件、场景环境、人物行为高度匹配，关键声音自然出现，几乎没有违和声源	整体匹配，少量声音细节缺失或略有不准，不完全遵循提示词，但不影响理解。	大体能对应场景，但声音较泛化，部分关键事件缺少声效，不遵循提示词，贴合度一般。	声音与画面只有弱关联，存在明显错配或大量缺失。	声音与画面基本无关，或音频内容严重干扰画面理解。
音频呈现力	声音情绪与画面高度一致，并能增强画面表达。	整体情绪匹配，少量节奏或氛围不够贴合。	能识别出基本情绪，但表达较平淡，或与画面氛围只有弱关联。	声音情绪与画面明显不搭，例如温馨画面配紧张音效、危险场景配轻快音乐。	声音情绪完全错误或氛围混乱，严重破坏画面理解。

3.规则维度评判角度

维度	角度				
画面质量	清晰度	压缩痕迹	画面卡顿/跳帧	过曝过暗	是否影响观看
画面遵循	主体动作响应	辅助主体响应	风格响应	镜头响应	环境响应
主体一致性	形象改变，侧脸和正脸不像同一人	五官/脸部稳定性	服装/发型/颜色一致性	主体数量一致性	主体消失/替换/身份漂移
运动质量	运动连续性	运动合理性	运动稳定性	运动生动性	
现实合理性	空间关系	重力错误	物理结构	材质真实度	光影逻辑

画面表现力	光影/色彩氛围	构图	情绪感、故事感	运镜美感	视觉感染力
音画同步	多/少口型	错口型	角色发声对应	画外音/旁白成口型	多/少音效
音频质量	人声清晰/口齿	人声卡顿	音效卡顿	杂音/噪音	音量异常
音频遵循	台词内容	主体人物遵循	声音数量响应	方言/语种/口音响应	音效缺失
音频呈现力	说话机械感重	口音/唱歌表现差	情绪表现不足	音效节奏不自然	整体氛围感不足

4.最终评分办法

- 针对每个场景进行模型评分排序，判断具体场景下的模型表现。
- 对评分进行模型总分相加，对每个模型的综合实力进行排名。

五、案例集

1.badcase集

[📖 Badcase集](#)

2.QA问答集

[📖 Q&A文档](#)